

**TERCER EVENTO EVALUATIVO**

**INTEGRANTES**

**SIMÓN ALEJANDRO VANEGAS RAMIREZ**

**SILVANA MONSALVE OSPINA**

**DIEGO ALEJANDRO RODRIGUEZ TAMAYO**

**JUAN DAVID ALVAREZ RAMIREZ**

**DOCENTE**

**DANIEL ALEXIS NIETO MORA**

**ANALISIS DE DATOS**

**MEDELLÍN**

**2026**

## **Fase 1: Comprension del problema**

El Dataset Churn Modelling se trata sobre el analisis de abandono de clientes, este dataset contiene alrededor de 10.000 registros de clientes, registros que describen características como la ubicación geográfica, comportamiento y elementos financieros que puedan afectar la decisión de seguir o abandonar el banco.

El conjunto de datos incluye variables como lo son la edad, genero, país de residencia, puntaje crediticio, saldo en cuenta, número de productos contratados, años de permanencia en el banco, actividad del cliente y salario estimado.

Los dataset de tipo Churn se suele utilizar normalmente en proyectos de analisis de datos y machine learning, ya que con este tipo de analisis se puede construir modelos que puedan anticipar que clientes tienen mas probabilidades de irse y así aplicar estrategias de retención

El problema central que hemos identificado se trata sobre la pérdida de clientes en una entidad bancaria, ya que cuando un cliente decide dar por terminado su relación con el banco, la entidad bancaria pierde un potencial dinero lo cual lleva a tener que invertir mas dinero en poder captar nuevos clientes

Es por ello que planteamos las siguientes preguntas clave

- ¿Existen diferencias en la tasa de abandono según el país de residencia del cliente?
- ¿El nivel de actividad del cliente influye en la probabilidad de que deje el banco?
- ¿Qué perfil de cliente tiene mayor riesgo de abandono y debería ser priorizado en estrategias de retención?

## Fase 2: Formulación de hipótesis

Teniendo en cuenta el análisis realizado en la comprensión del dataset y con las preguntas claves realizadas previamente, hemos optado por la formulación de las siguientes hipótesis:

### Hipótesis 1: Influencia en la actividad del cliente en el abandono

Para esta primera hipótesis podemos identificar 2 variables que nos ayudara con la duda, y estas son:

- IsActiveMember (Si es activo 1 sino 0)
- Exited (Si el cliente abandonó 1, si permanece 0)
- H0: El nivel de actividad del cliente no tiene relación con la probabilidad de abandono del banco
- H1: Los clientes no activos tienen mayor probabilidad de abandonar el banco que los clientes activos.

Esto se debe a que un cliente activo suele reflejar el compromiso con la entidad bancaria, dado a que clientes que usan activamente los productos o servicios del banco suelen mantener una relación más estable con la entidad, si se logra confirmar que los clientes inactivos son los que más terminan su relación con el banco, entonces el banco podría diseñar una estrategia enfocada en reactivar esos clientes antes de que lleguen a abandonar.

### Hipótesis 2: Perfil de cliente con mayor riesgo de abandono

Para esta segunda hipótesis con un enfoque más general, logramos identificar varias variables que nos ayudara las cuales son:

- Age (edad del cliente)
- IsActiveMember (si es cliente activo o no)
- NumOfProducts (número de productos contratados)
- Balance (saldo en cuenta)
- Exited (abandono del cliente)
- H0: Las características del cliente (edad, actividad, número de productos y saldo) no influyen en la probabilidad de abandono del banco.
- H1: Existe un perfil de cliente específico que presenta mayor probabilidad de abandonar el banco.

Identificar el perfil de cliente que cuenta con mayor riesgo de abandono es clave para las estrategias de retención de clientes que el banco pueda ejercer, ya que con esa identificación de

perfiles se puede implementar estrategias tales como promociones personalizadas, campañas de fidelización, mejoras de servicio, entre otros.

Permitiendo reducir la pérdida de clientes y aumentar así la rentabilidad de la entidad, dado que retener clientes existentes suele ser menos costoso que adquirir nuevos.

## Fase 3: Preparación y modelado de datos

Primero, eliminamos el ruido. Descartamos columnas como RowNumber, CustomerId y Surname ya que no tienen valor predictivo y aplicamos limpieza básica.

### 3.1 Limpieza Básica

Eliminamos columnas que no aportan valor analítico por su alta cardinalidad o por ser identificadores únicos. También tratamos nulos y duplicados.

```
columnas_a_eliminar = ['RowNumber', 'CustomerId', 'Surname']
df.drop(columns=[col for col in columnas_a_eliminar if col in df.columns], inplace=True)

# Tratamiento de valores nulos (Imputación con mediana y moda)
num_cols = df.select_dtypes(include=[np.number]).columns
cat_cols = df.select_dtypes(include=['object']).columns

df[num_cols] = df[num_cols].fillna(df[num_cols].median())
for col in cat_cols:
    df[col] = df[col].fillna(df[col].mode()[0])

# Eliminar registros duplicados
df.drop_duplicates(inplace=True)
```

[3] Python

tomamos la variable CreditScore y le aplicamos un suavizado mediante el Rango Intercuartílico para evitar sesgos dentro de los modelos estadísticos.

### 3.2 Tratamiento de Outliers y Conversión de Tipos

Aplicamos una técnica de capping suave utilizando el Rango Intercuartílico (IQR) para atenuar el efecto de valores extremos en CreditScore, y lo convertimos a entero.

```
if 'CreditScore' in df.columns:
    Q1 = df['CreditScore'].quantile(0.25)
    Q3 = df['CreditScore'].quantile(0.75)
    IQR = Q3 - Q1
    lower_bound = Q1 - 1.5 * IQR
    upper_bound = Q3 + 1.5 * IQR

    df['CreditScore'] = np.where(df['CreditScore'] < lower_bound, lower_bound, df['CreditScore'])
    df['CreditScore'] = np.where(df['CreditScore'] > upper_bound, upper_bound, df['CreditScore'])

    # Conversión a entero
    df['CreditScore'] = df['CreditScore'].astype(int)
```

] Python

tomamos nuestras tres variables binarias clave (HasCrCard, IsActiveMember y nuestra variable objetivo Exited) y las transformamos a etiquetas de texto en inglés (Yes/No y Churn/Retained), esto para no destruir la información Cuantitativa.

además duplicamos estas columnas antes de transformarlas. Así creamos HasCrCard\_num, IsActiveMember\_num y Exited\_num manteniendo sus ceros y unos originales, Esto fue para que nuestro dataset tuviera compatibilidad tanto para BI en PowerBI como para la prueba de hipótesis

### 3.3 Formateo de Variables para BI y Preservación de Variables Numéricas Originales

PowerBI y Tableau funcionan mejor con variables categóricas descriptivas en inglés. Además, se mantienen las variables binarias originales (con sufijo `_num`) para posteriores pruebas de hipótesis.

```
if 'HasCrCard' in df.columns:
    df['HasCrCard_num'] = df['HasCrCard']
    df['HasCrCard'] = df['HasCrCard'].map({1: 'Yes', 0: 'No'})
    ...

if 'IsActiveMember' in df.columns:
    df['IsActiveMember_num'] = df['IsActiveMember']
    df['IsActiveMember'] = df['IsActiveMember'].map({1: 'Yes', 0: 'No'})
    ...

if 'Exited' in df.columns:
    df['Exited_num'] = df['Exited']
    df['Exited'] = df['Exited'].map({1: 'Churn', 0: 'Retained'})
```

Para enriquecer el análisis, agrupamos tres variables continuas en nuevas dimensiones categóricas. Esto evita tener que graficar miles de números sueltos y tener una mejor vista estratégica.

### 3.4 Creación de Dimensiones (Categorización)

Agrupamos variables continuas en categorías (solo etiquetas, sin rangos, en inglés) para facilitar la creación de gráficos y filtros en los dashboards.

```
# Grupos de Edad
if 'Age' in df.columns:
    bins_age = [0, 30, 50, 150]
    labels_age = ['Young', 'Adult', 'Senior']
    df['AgeGroup'] = pd.cut(df['Age'], bins=bins_age, labels=labels_age, right=False)

# Grupos de Credit Score
if 'CreditScore' in df.columns:
    bins_score = [0, 500, 650, 750, 900]
    labels_score = ['Poor', 'Fair', 'Good', 'Excellent']
    df['CreditScoreGroup'] = pd.cut(df['CreditScore'], bins=bins_score, labels=labels_score, right=False)

# Grupos de Saldo (Balance)
if 'Balance' in df.columns:
    bins_balance = [-1, 0, 100000, float('inf')]
    labels_balance = ['No Balance', 'Medium', 'High']
    df['BalanceGroup'] = pd.cut(df['Balance'], bins=bins_balance, labels=labels_balance, right=True)

df[['Age', 'AgeGroup', 'CreditScore', 'CreditScoreGroup', 'Balance', 'BalanceGroup']].head()
```

## Fase 4: Definición de KPI's

Definimos KPIs enfocados en entender la fuga de clientes desde distintas dimensiones: comportamiento (actividad), perfil (edad, país) y relación con el banco (productos y saldo). Cada indicador nos permite validar hipótesis sobre qué factores influyen en el churn y así proponer estrategias de retención.

## 1. KPI 1: Tasa de Churn

- Definición: Porcentaje de clientes que abandonan el banco.
- Fórmula:

$$\text{Churn Rate} = \frac{\text{Clientes que se fueron}}{\text{Total de clientes}}$$

- Variable: Exited
- Justificación (negocio): Es el indicador más importante: si el churn sube → el banco pierde dinero.
- Hipótesis relacionada: “Los clientes menos activos tienen mayor probabilidad de abandonar”
- Interpretación
  - o Alto → problema grave de retención
  - o Bajo → buena fidelización

## 2. KPI 2: Tasa de churn por país

- Definición: Porcentaje de clientes que se van según Geography.
- Justificación: Permite identificar mercados problemáticos.
- Hipótesis: “El churn varía según el país”
- Interpretación: Si un país tiene mayor churn → mala estrategia local o competencia fuerte

### 3. KPI 3: Tasa de churn de clientes activos vs inactivos

- Definición: Comparar churn entre:
  - o IsActiveMember = 1
  - o IsActiveMember = 0
- Justificación: La actividad del cliente suele estar ligada a retención.
- Hipótesis: “Los clientes inactivos tienen mayor churn”
- Interpretación: Si inactivos tienen más churn → hay que activar clientes (campañas, beneficios)

### 4. KPI 4: Balance promedio de clientes que se van vs los que se quedan

- Definición: Promedio de Balance según Exited.
- Justificación: Indica cuánto dinero está en riesgo.
- Hipótesis: “Clientes con mayor saldo tienen mayor impacto si abandonan”
- Interpretación:
  - o Si los que se van tienen alto saldo → pérdida económica fuerte
  - o Si tienen bajo saldo → impacto menor pero puede indicar desinterés

### 5. KPI 5: Churn según número de productos


- Definición: Relación entre NumOfProducts y churn.
- Justificación: Más productos = mayor vinculación con el banco.

- Hipótesis: “Clientes con menos productos tienen mayor churn”
- Interpretación
  - o Si 1 producto → alto churn → falta de fidelización
  - o Si 3+ productos → bajo churn → buena estrategia de cross-selling

## **Fase 5: Desarrollo del Dashboard**

### **1. DashBoard Ejecutivo**





- La tasa general de churn es 20.37%
- Clientes inactivos abandonan más
- Germany presenta mayor riesgo
- Clientes churn tienen balances altos
- Activación temprana reduce fuga

## 2. DashBoard KPIs



### 1. Tasa de churn por país:

- Germany = 39.96%
- France = 39.76%
- Spain = 20.27%

**Interpretación:** Alemania y Francia presentan niveles altos de abandono.

**Conclusión ejecutiva:** España retiene mejor a sus clientes.

### 2. Porcentaje de abandono por edad

- Adult
- Senior
- Young

**Hallazgo:** Adultos concentran más churn.

**Interpretación:** Probablemente porque también son mayoría en clientes.

### 3. Porcentaje de abandono por Estado de Cliente (Activo vs Inactivo)

- Inactivos = 65.3%
- Activos = 34.7%

**Interpretación:** Los clientes inactivos tienen mayor probabilidad de abandonar.

**Conclusión:** La inactividad es una señal temprana de churn.

## Fase 6: Análisis, validación y storytelling

### 1. Interpretación de resultados

El análisis muestra que, de 10,000 clientes, 2,037 abandonaron la entidad, equivalente a una tasa de abandono del 20.37%.

Los principales hallazgos fueron:

- Alemania tiene la mayor tasa de churn: 32.44%.
- Los clientes inactivos presentan más abandono: 26.85%, frente a 14.27% en clientes activos.
- Los clientes que abandonan tienen un balance promedio mayor: aproximadamente 91,108, frente a 72,745 en clientes retenidos.
- Los clientes con 3 y 4 productos presentan tasas críticas de churn: 82.7% y 100%.
- Los clientes Senior tienen mayor Abandono: 45.45%.

### 2. Validación de hipótesis mediante pruebas estadísticas

#### Hipótesis 1: Influencia de la actividad del cliente en el abandono

Variables utilizadas:

- IsActiveMember
- Exited

Hipótesis planteadas:

- H0: El nivel de actividad del cliente no tiene relación con la probabilidad de abandono.
- H1: Los clientes no activos tienen mayor probabilidad de abandonar que los activos.

Prueba estadística utilizadas:

- Chi-cuadrado de independencia
- Porque ambas variables son categóricas:
- Activo / No activo
- Abandonó / No abandonó

Resultado observado:

- En el dashboard se evidenció que:
- Clientes activos abandonan menos
- Clientes inactivos concentran mayor abandono
- Valor p:  $p < 0.05$

Decisión:

- Se rechaza H0 y se acepta H1.

**Conclusión:** Existe evidencia estadística para afirmar que los clientes inactivos tienen mayor probabilidad de abandonar el banco.

**Interpretación empresarial:** Esto sugiere que la inactividad puede funcionar como una alerta temprana de abandono, permitiendo campañas preventivas.

## **Hipótesis 2: Perfil de cliente con mayor riesgo de abandono**

Variables utilizadas:

- Age
- IsActiveMember
- NumOfProducts
- Balance
- Exited

Hipótesis planteadas:

- H0: Las características del cliente no influyen en la probabilidad de abandono.
- H1: Existe un perfil específico de cliente con mayor probabilidad de abandonar.

Validación por variable:

- Edad vs Churn
- Prueba: t-test o ANOVA

Resultado:

- Clientes mayores muestran mayor abandono.
- $p < 0.05$

Actividad vs Churn:

- $p < 0.05$

Número de productos vs Churn:

- Chi-cuadrado
- Resultado:
- Clientes con más productos presentan mayor abandono.
- $p < 0.05$

Balance vs Churn

- Prueba:
- t-test

Resultado:

- Clientes que abandonan tienen mayor balance promedio.
- $p < 0.05$

Decisión general:

- Se rechaza H0 y se acepta H1.

Conclusión:

- Sí existe un perfil de cliente con mayor riesgo de abandono.

Perfil identificado con mayor churn:

- Cliente inactivo
- Mayor edad

- Balance alto
- Varios productos contratados

### **3. Uso del valor p para toma de decisiones**

Se utilizó un nivel de significancia:

- $\alpha = 0.05$

Regla:

- Si  $p < 0.05 \rightarrow$  relación significativa
- Si  $p \geq 0.05 \rightarrow$  no concluyente

Aplicación práctica:

Como las variables analizadas dieron p menor a 0.05:

- Actividad sí importa
- Edad sí importa
- Balance sí importa
- Productos sí importan

Por tanto, deben considerarse en estrategias de retención.

### **4. Construcción de narrativa con los datos**

La historia que cuentan los datos es la siguiente:

La entidad bancaria tiene una tasa de abandono del 20.37%, lo que representa una pérdida importante de clientes. El problema no está distribuido de forma uniforme: Alemania concentra el mayor riesgo de abandono, los clientes inactivos abandonan mucho más que los activos, y los clientes que se van tienen un balance promedio más alto que los que permanecen. Esto indica que el banco no solo pierde clientes, sino clientes financieramente valiosos. Además, los clientes con 3 o 4 productos presentan una tasa de abandono alarmante, lo que puede indicar insatisfacción, mala experiencia o sobrecarga de productos.

## 5. Propuesta de decisiones basadas en evidencia

- **Decisión 1:** Priorizar Alemania

Como Alemania tiene el abandono más alto, se recomienda hacer campañas de retención específicas en ese país.

- **Decisión 2:** Reactivar clientes inactivos

Los clientes inactivos tienen mayor abandono. Se recomienda crear campañas de contacto, beneficios personalizados y seguimiento preventivo.

- **Decisión 3:** Revisar clientes con 3 y 4 productos

Este segmento tiene churn extremadamente alto. Puede existir mala experiencia, exceso de productos o falta de acompañamiento comercial.

- **Decisión 4:** Proteger clientes con alto balance

Los clientes churn tienen mayor balance promedio. Se recomienda crear alertas para clientes de alto valor con señales de abandono.

- **Decisión 5:** Diseñar campañas para clientes Senior

El grupo Senior presenta mayor tasa de abandono. Se recomienda mejorar la atención, simplificar procesos y ofrecer acompañamiento personalizado.

## 6. Discusión de limitaciones

El análisis tiene varias limitaciones importantes:

- El dataset no tiene información temporal real, por lo tanto no se puede analizar evolución histórica del abandono.
- No se conoce la causa exacta del abandono.
- Algunas variables pueden estar relacionadas, pero eso no significa causalidad.
- No hay información sobre satisfacción del cliente, reclamos, contacto con asesores o experiencia digital.
- El campo Balance no especifica moneda.

- El dato de clientes con 4 productos es pequeño, por eso el 100% de abandono debe interpretarse con cuidado.
- El dashboard describe patrones, pero no predice automáticamente futuros abandonos.